

Assignment3 : Marabou Verification Report

Structure

- Model : timeout을 방지하기 위해 Pytorch를 사용하여 입력층-은닉층-출력층으로 구성된 단순한 형태의 Fully Connected Network(FCN)를 설계하였다. 학습 속도와 가독성을 위해 100배치 단위로 손실값을 기록하며 1 epoch만 학습시킨 후 ONNX 포맷으로 변환하였다.
- Dataset : MNIST 데이터셋을 사용하였으며, 타겟 클래스는 '3'으로 설정하였다. Base Image는 모든 픽셀 값이 0.5으로 설정된 임의의 이미지를 사용하였다.
- Verification Query : L_∞ -ball을 기준으로 반경 ϵ 내에 있는 입력값이 주어졌을 때, 타겟 클래스(3)가 아닌 다른 클래스(j)의 출력값이 타겟 클래스의 출력값보다 크거나 같아지는(즉, 모델이 오분류하는) 반례가 존재하는지 확인하는 쿼리를 작성했다.

Results

실험은 ϵ 값을 0.01, 0.05, 0.1, 0.3, 0.5로 점진적으로 증가시키며 진행하였으며, 결과는 result_log.txt 파일에서 확인할 수 있다.

- $\epsilon = 0.01$: SAT (반례 발견됨). 모델은 원래 클래스인 3 대신 5로 오분류했다.
- $\epsilon = 0.05$: SAT (반례 발견됨). 모델은 원래 클래스인 3 대신 2로 오분류했다.
- $\epsilon = 0.1$: SAT (반례 발견됨). 모델은 원래 클래스인 3 대신 0로 오분류했다.
- $\epsilon = 0.3$: SAT (반례 발견됨). 모델은 원래 클래스인 3 대신 0로 오분류했다.
- $\epsilon = 0.5$: SAT (반례 발견됨). 모델은 원래 클래스인 3 대신 0로 오분류했다.

일반적인 신경망이라면 $\epsilon = 0.01$ 과 같이 미세한 노이즈에서는 unsat해야하지만, 본 실험에서는 아주 작은 perturbation에도 즉각적으로 모델이 sat한 예기치 못한 취약성이 관찰되었다. 이는 모델 구조가 단순하고 1 epoch만 학습되었기 때문에 decision boundary가 허술하게 형성되었기 때문으로 추론된다.

특히 로그에 기록된 반례의 픽셀 값들을 분석해보면, $\epsilon = 0.1$ 일 때 SMT 솔버가 픽셀 값들을 정확히 0.4 또는 0.6이라는 lower/upper bounds로만 붙여 최적의 적대적 공격을 구성했음을 확인할 수 있다. 이는 Marabou가 휴리스틱이 아닌 수학적 경계를 탐색하는 도구임을 보여준다.

Discussion

- Strengths : PGD나 FGSM같은 기존의 휴리스틱 기반의 적대적 공격은 반례를 찾

지 못했다는 것이 모델이 100% 안전하다고 보장할 수 없다. 하지만 Marabou는 SMT 기반의 formal verification을 수행하므로, 결과가 unsat으로 나오면 해당 ϵ 범위 내에서는 수학적으로 안전하다는 것을 확실히 보증할 수 있다.

- Limitations : 데이터 타입과 차원에 매우 엄격하여 OONX 모델을 로드하고 제약 조건을 설정할 때 형 변환 작업이 까다롭다. 또한, 연산 복잡도가 높아 ResNet 등의 복잡한 모델에 적용하기에는 확장성 측면에서 한계가 있다.